

Proyecto Curso I – Especialización Machine Learning Engineering

El proyecto del curso I de la especialización de Machine Learning Engineering tiene como objetivo enfrentar al estudiante a casos de negocio reales donde se debe estructurar desde el inicio un proyecto con requerimientos y metas específicas, pero pensando en su escalabilidad y desempeño a largo plazo. Por el alcance del curso solo se evaluarán las siguientes herramientas:

- Python (pero se fomentará el uso de POO y principios SOLID)
 - o <https://www.freecodecamp.org/espanol/news/los-principios-solid-explicados-en-espanol/>
 - o <https://ellibrodepython.com/programacion-orientada-a-objetos-python>
- Conocimiento teórico de algoritmos tradicionales de Machine Learning (Modelos lineales, algoritmos basados en árboles y técnicas no supervisadas básicas)
- Uso y entendimiento de LLMs
- Git básico
- ML Project Management

Entregable: Repositorio de GitHub en versión 1.0.0 con las siguientes secciones:

1. README.md
 - a. Problema de ML
 - b. Diagrama de flujo del proyecto
 - c. Descripción del dataset con su respectivo diccionario de datos
 - d. Model Card <https://www.kaggle.com/code/var0101/model-cards>
 - e. Resultados con métricas de evaluación offline y online
 - f. Conclusiones
2. Estructura del repositorio de código con:
 - a. Carpeta de notebooks
 - i. Notebook preprocesamiento de datos
 - ii. Notebook de Machine Learning y LLMs
 - b. Carpeta de datos (.csv, .txt, .parquet)
 - c. Carpeta de artefactos (.pkls, .htmls, .csv)
 - d. [OPCIONAL] Módulo de código reusable
 - e. [OPCIONAL] Scripts de ejecución (preprocesamiento, entrenamiento y predicción)
3. Release de la versión 1.0.0 con sus respectivas notas <https://docs.github.com/es/repositories/releasing-projects-on-github/managing-releases-in-a-repository>

4. Ramas Main y Development (al menos una pull request cerrada exitosamente)
5. Documentación sobre la estrategia de Git utilizada
6. [OPCIONAL] Otros (.gitignore, requirements.txt, instrucciones de ejecución)

Indicaciones Generales del proyecto

1. El conjunto de datos es de libre elección. Se sugiere utilizar las siguientes fuentes para seleccionar un conjunto de datos:
 - a. Kaggle <https://www.kaggle.com/datasets>
 - b. Google Datasets <https://datasetsearch.research.google.com/>
 - c. UCI datasets <https://archive.ics.uci.edu/datasets>
 - d. Public APIs: <https://github.com/public-apis/public-apis>
2. Definir el problema de Machine Learning que se quiere resolver (Supervisado, no supervisado) y el subconjunto de problemas (Regresión, clasificación, Clustering, Reducción de dimensiones).
3. Elegir las métricas de evaluación acorde al problema de ML que se quiere resolver.

Sugerencias para el proyecto

- Usar datasets tabulares de tamaño no mayor a 100MB, además se recomienda no usar datos que requieran procesos de ingeniería de datos complejos, pues esto no será evaluado.
- Crear estructura del proyecto con cookiecutter <https://www.cookiecutter.io/>
- Usar librerías populares para Data Science y ML (Scikit Learn, Statsmodels, pandas, numpy, openai).
- Revisar la guía básica de Markdown para preparar el README.md con mejor estructura. <https://markdown.es/>
- Agregar excepciones adicionales para archivos que estemos manejando. <https://docs.github.com/es/get-started/git-basics/ignoring-files>
- Usar gitkeep en carpetas provisionales del proyecto (data, tmp, etc).
- Para los Pull Request, documentarlos acorde a los cambios y usar **git and merge** para fusionarlos con la rama main. (Se recomienda github Flow <https://docs.github.com/es/get-started/using-github/github-flow>)
- Accesos a APIs gratuitas de AI
 - o Gemini Free Tier: <https://ai.google.dev/gemini-api/docs/pricing>
 - o Groq Free Tier: <https://console.groq.com/docs/rate-limits>
 - o Ollama: <https://ollama.com/search?c=>
 - o HuggingFace: <https://huggingface.co/>

Evaluación

Componente	Tipo	Descripción	Porcentaje en la evaluación
Repositorio de Github	Obligatorio	El estudiante presenta su proyecto de acuerdo con la estructura definida por el profesor.	50%
Machine Learning y AI	Obligatorio	El estudiante documenta y desarrolla un modelo de machine learning o usa LLMs alineado con sus hipótesis, además de evaluarlo con métricas que tengan sentido para el problema que previamente escogió	25%
Buenas prácticas de desarrollo	Obligatorio	El estudiante sigue el proceso estándar de desarrollo basado en control de versiones, usando commits, pull requests y releases en su proyecto.	15%
Documentación	Obligatorio	El estudiante documenta el repositorio con archivos tipo markdown, o jupyter notebooks, así como también el código generado con docstrings, naming conventions, etc.	10%
Reto ML 1	Opcional	El estudiante demuestra dominio de los algoritmos vistos en clase realizando experimentos con más de uno y obteniendo resultados excepcionales (estos dependerán e tipo de problema que se busque resolver)	10% [Acumulable para todos los cursos de la especialización]
Reto ML2	Opcional	El estudiante construye scripts que permiten la automatización de tareas de preparación y entrenamiento de algoritmos de ML, usando funciones, clases y parámetros.	10% [Acumulable para todos los cursos de la especialización]

Instrucciones de Envío

En el classroom del curso se habilitará una tarea donde se debe colocar el enlace del repositorio de github con la estructura previamente definida (Para la fecha de entrega final no debe haber ningún commit adicional y el repositorio debe estar en la versión 1.0.0).

NOTA: El enlace del repositorio lo pueden compartir desde su creación, **El entregable se evaluará con el último commit del 6 de Junio de 2026.**

En caso de dudas adicionales, estas serán atendidas por los canales de comunicación habituales.